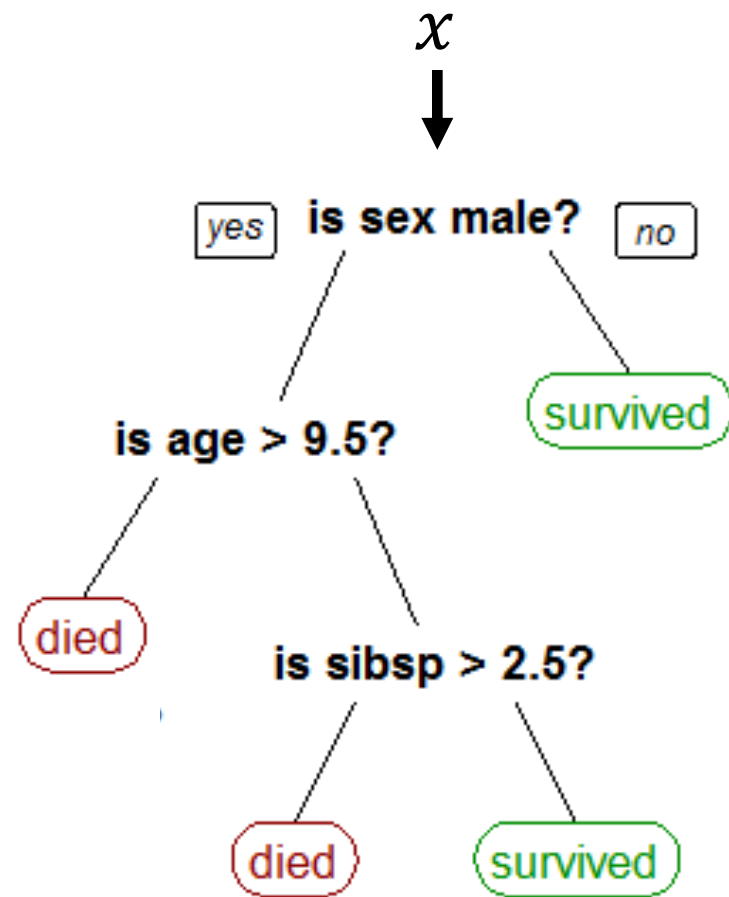


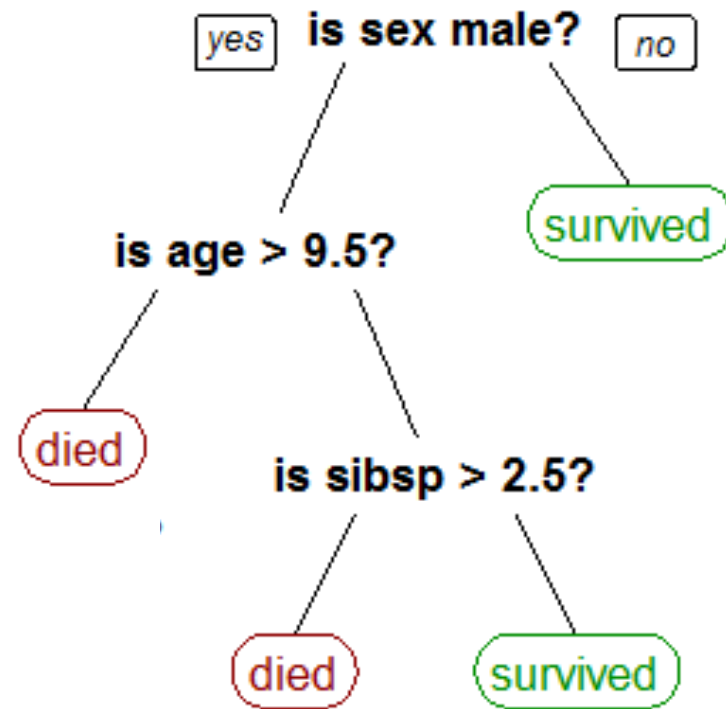
1. Что такое решающие деревья

Решающее дерево

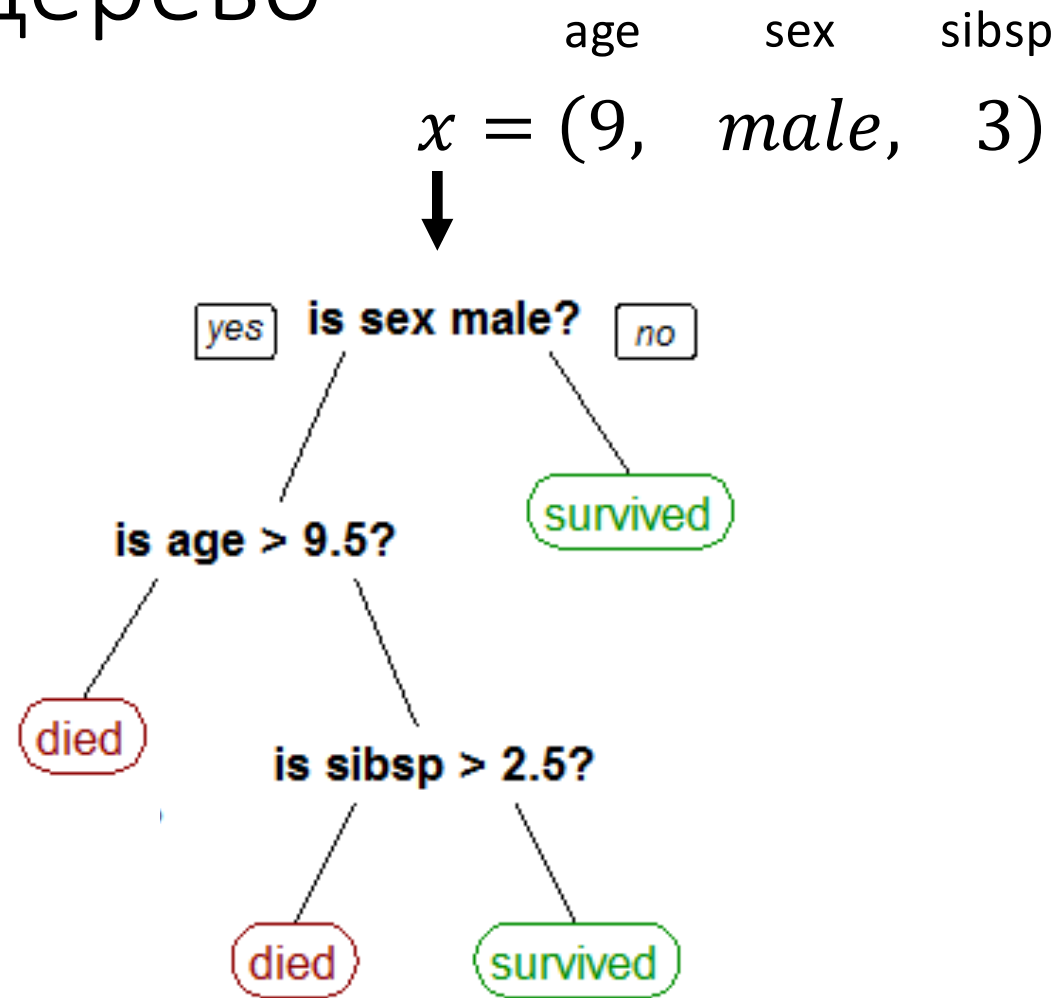


Решающее дерево

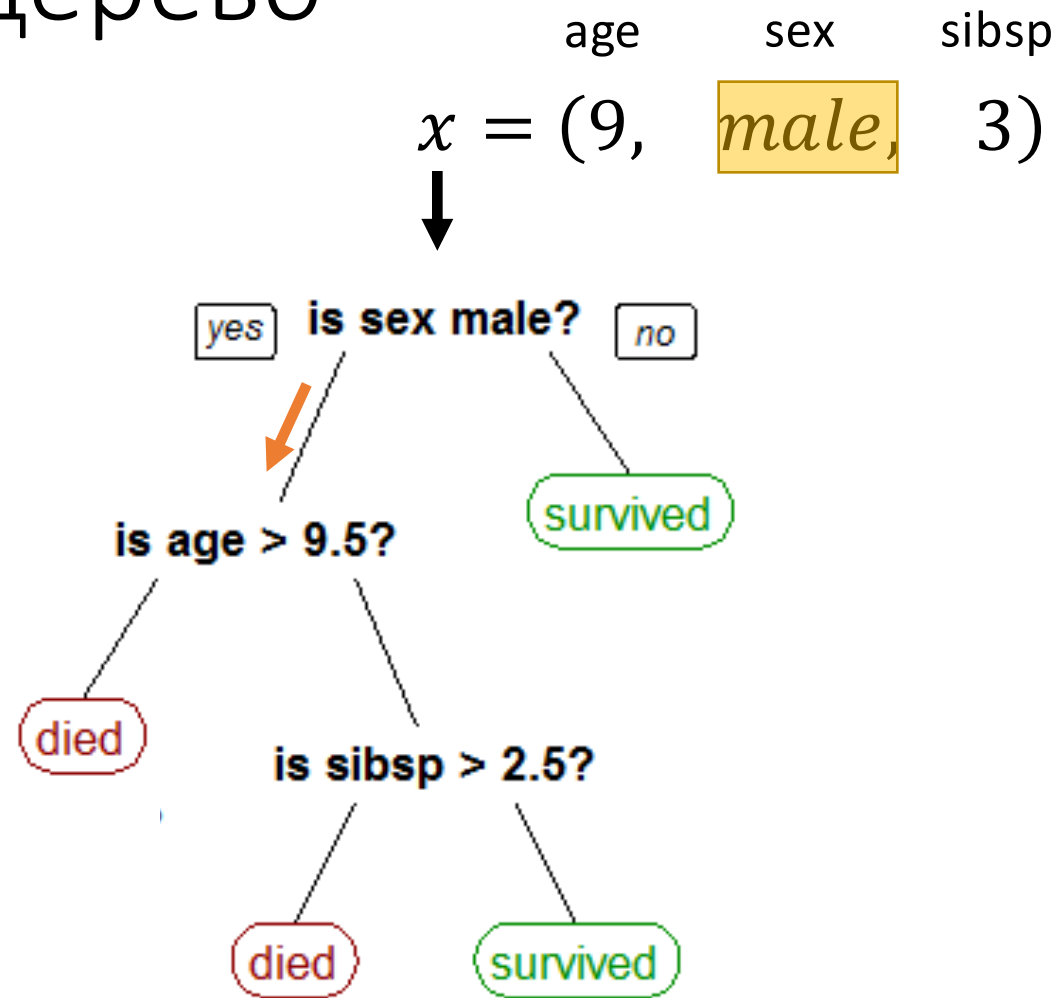
$x = (9, \text{male}, 3)$



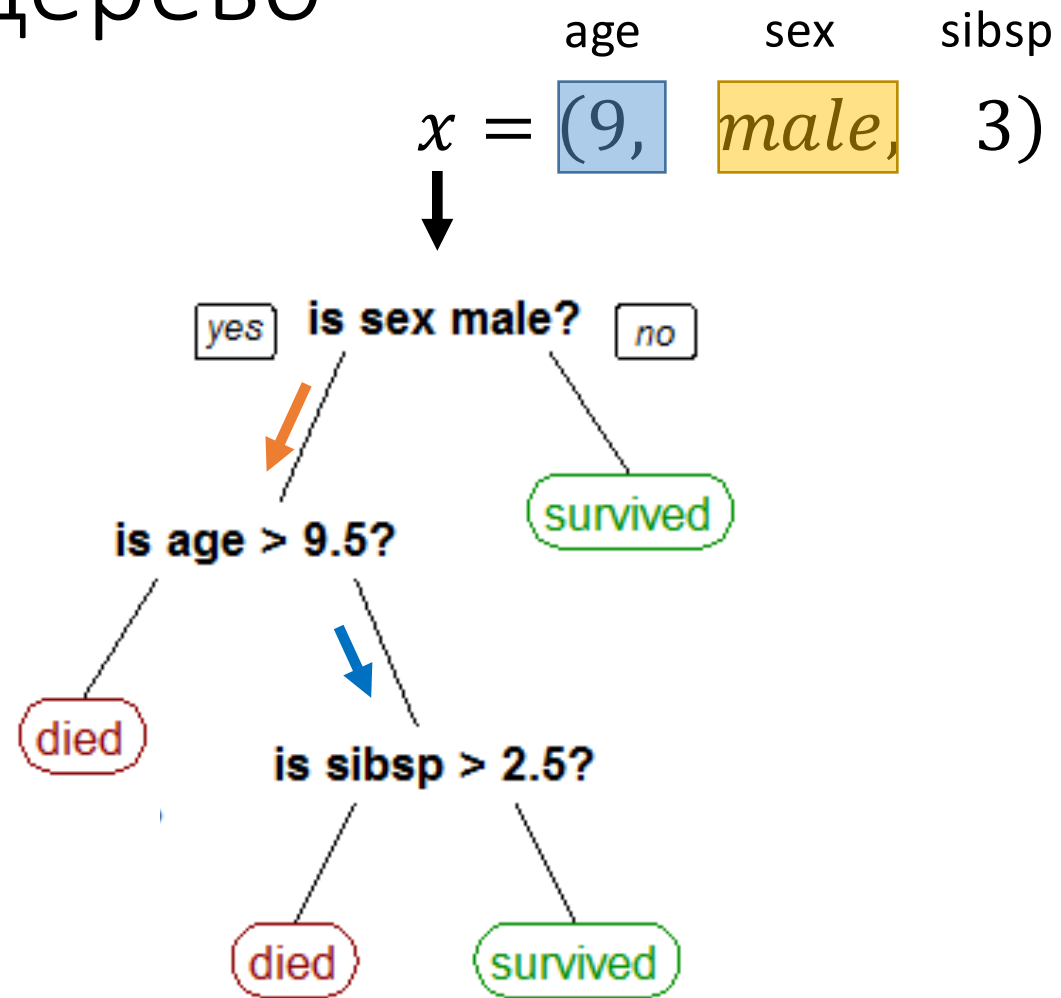
Решающее дерево



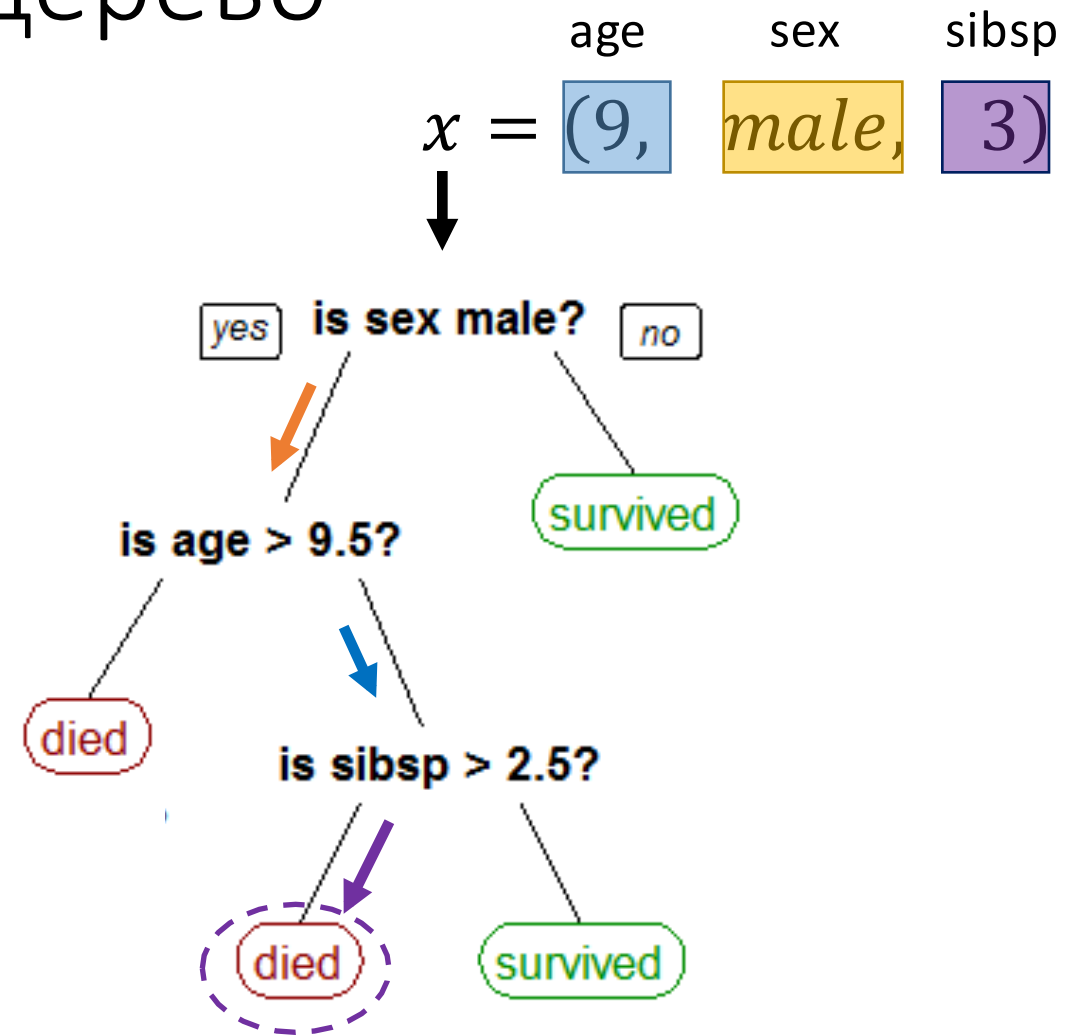
Решающее дерево



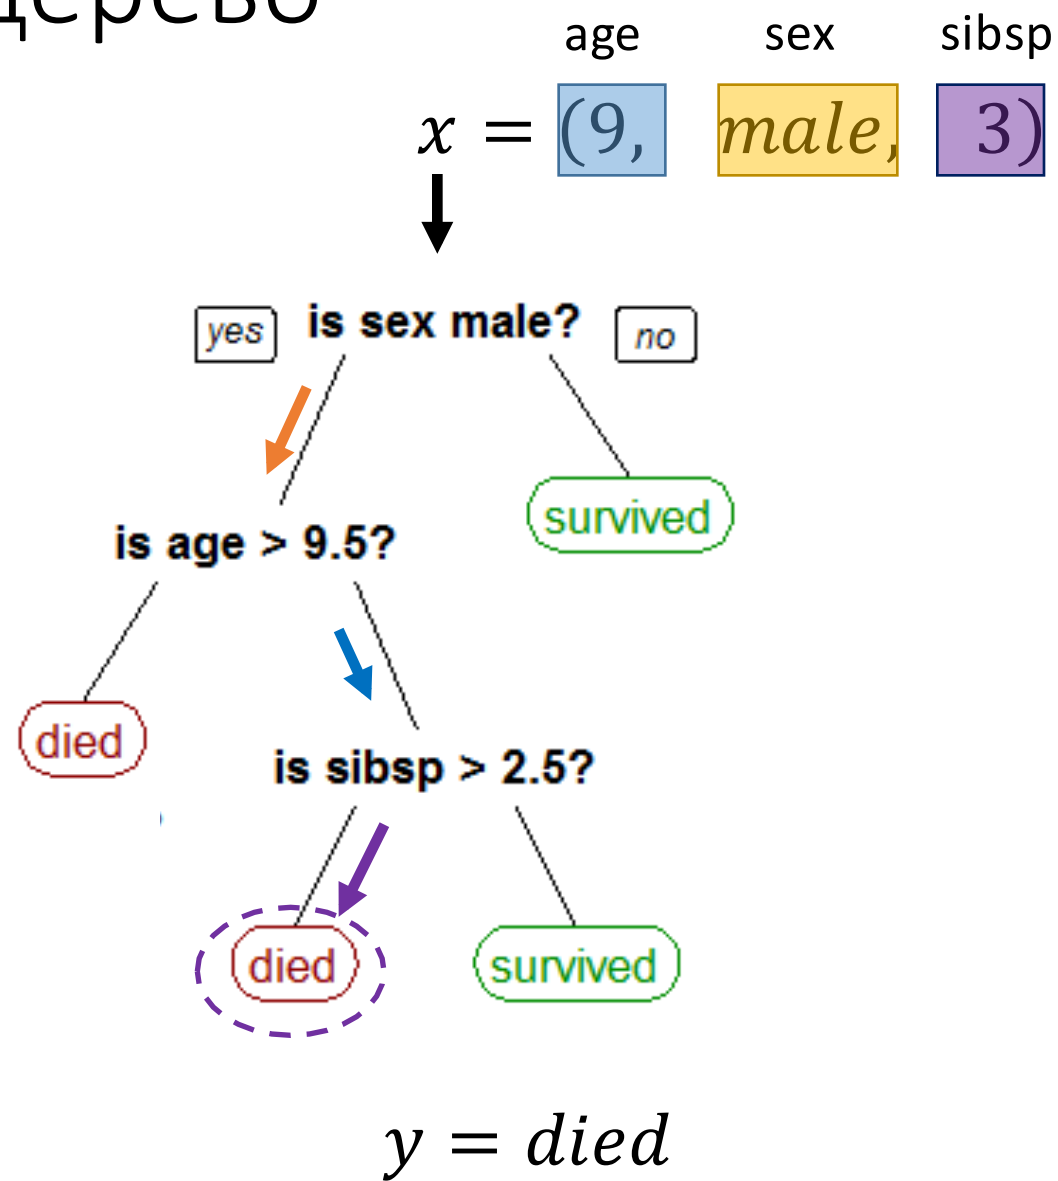
Решающее дерево



Решающее дерево

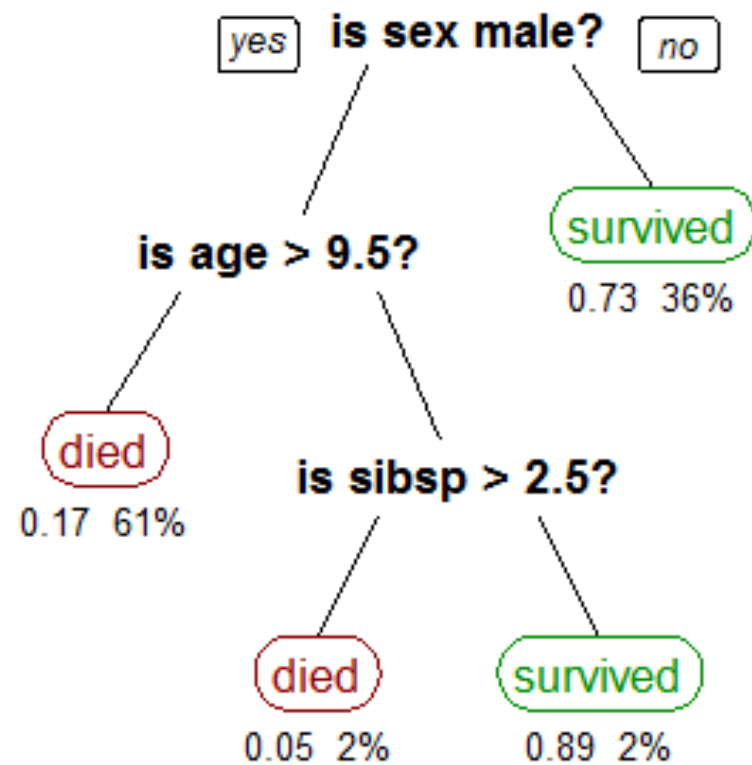


Решающее дерево

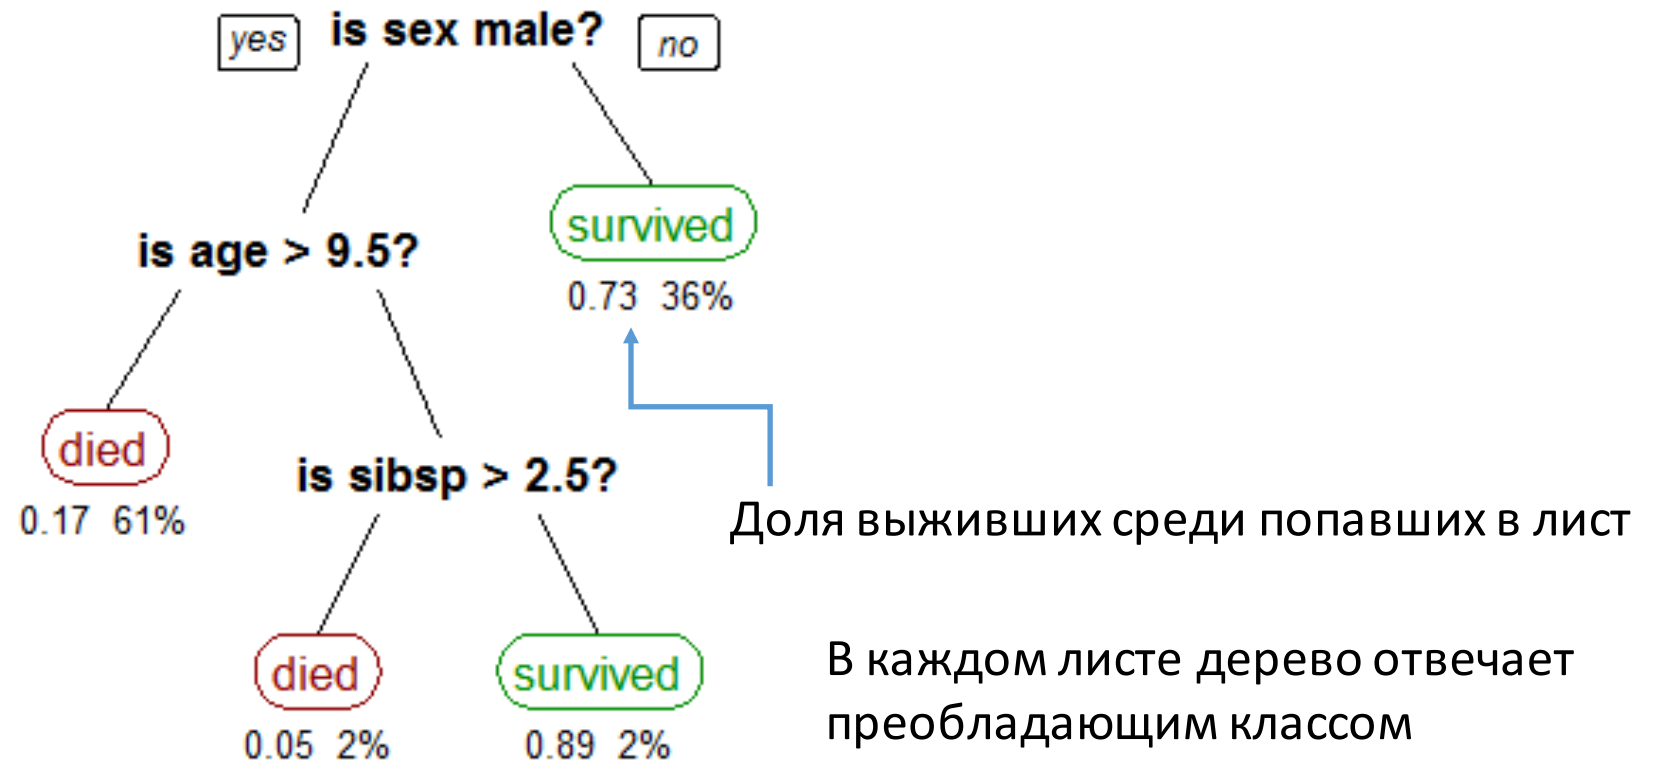


2. Решающие деревья в классификации и регрессии

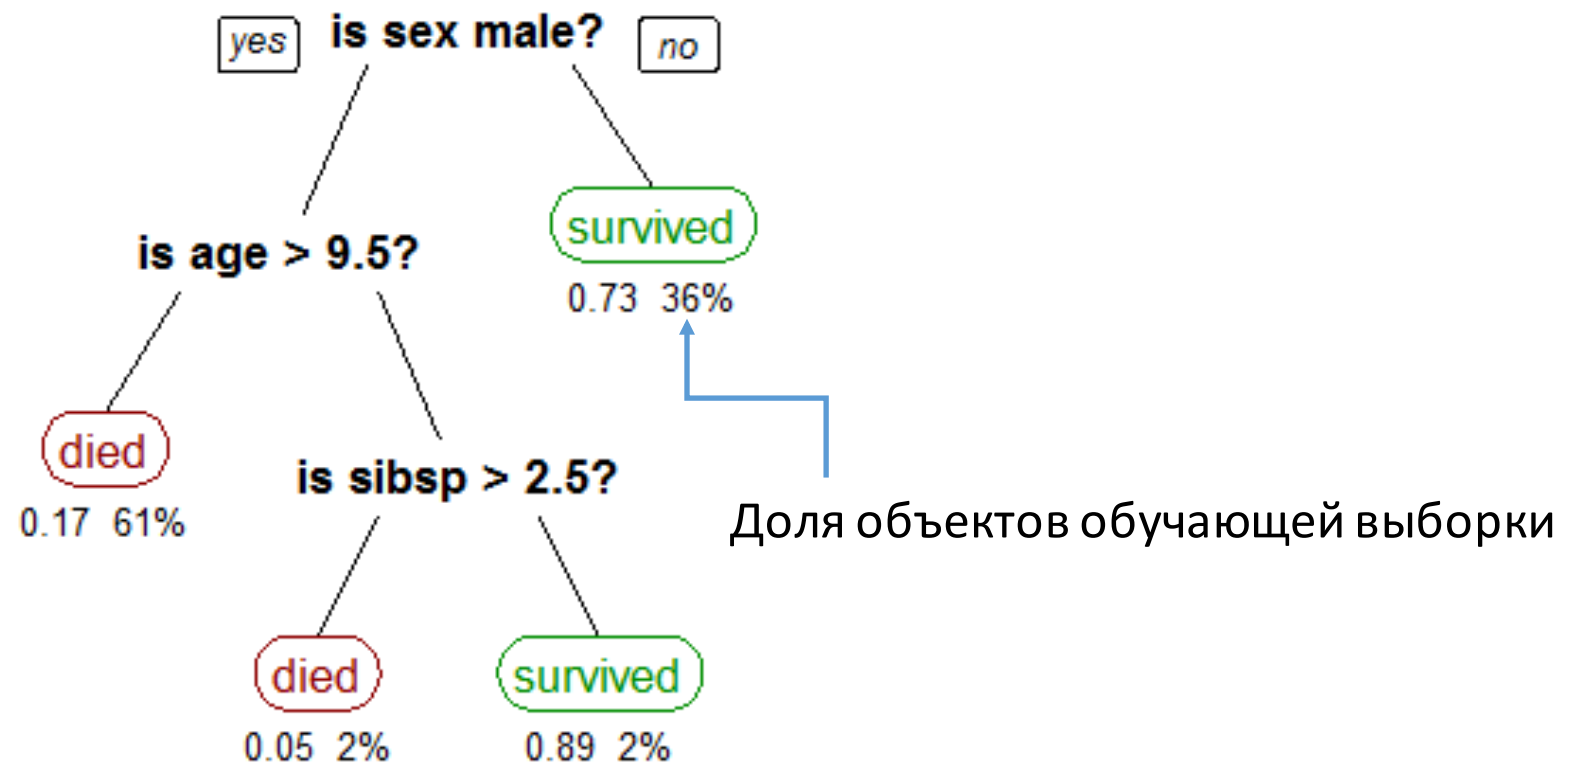
Решающее дерево: классификация




Решающее дерево: классификация



Решающее дерево: классификация




Решающее дерево: классификация



Пример: 3 класса и 2 признака

Решающее дерево: регрессия



Пример: восстановление зависимости $y(x) = \sin x$ с помощью решающих деревьев глубины 2 и глубины 5

В каждом листе дерево отвечает некоторой константой

3. Как строить решающие деревья

Рекурсивное построение

Строим разбиение
выборки по значению
одного из признаков

$$x^{(j)} < t$$


Рекурсивное построение

Строим разбиение
выборки по значению
одного из признаков

$$x^{(j)} < t$$

Фактически нужно
только выбрать j и t
наилучшим образом


Рекурсивное построение



Выборка делится
по этому условию
на две части

Рекурсивное построение


В каждой из них
теперь тоже можно
сделать разбиение



Выборка делится
по этому условию
на две части


Рекурсивное построение

В каждой из них
теперь тоже можно
сделать разбиение



Рекурсивное построение

В каждой из них
теперь тоже можно
сделать разбиение



Процесс можно продолжать в тех узлах, в
которые попадает достаточно много объектов


Выбор разбиения

Q




$$x^{(j)} < t$$

Выбор разбиения




Выбор разбиения




$$G(j, t) = \frac{|L|}{|Q|} H(L) + \frac{|R|}{|Q|} H(R)$$

Выбор разбиения



$$G(j, t) = \frac{|L|}{|Q|} H(L) + \frac{|R|}{|Q|} H(R) \rightarrow \min_{j, t}$$

Выбор разбиения



$$G(j, t) = \frac{|L|}{|Q|} H(L) + \frac{|R|}{|Q|} H(R) \rightarrow \min_{j, t}$$

$H(R)$ - мера «неоднородности» множества R

Критерии построения разбиений

$H(R)$ — мера «неоднородности» множества R

Критерии построения разбиений

$H(R)$ — мера «неоднородности» множества R

Пусть мы решаем задачу классификации на 2 класса,
 p_0, p_1 — доли объектов классов 0 и 1 в R

1) Misclassification criteria: $H(R) = 1 - p_{\max}$

2) Entropy criteria: $H(R) = -p_0 \ln p_0 - p_1 \ln p_1$

3) Gini criteria: $H(R) = 1 - p_0^2 - p_1^2 = 2p_0p_1$

Критерии построения разбиений

$H(R)$ — мера «неоднородности» множества R

Пусть мы решаем задачу классификации на K классов,
 p_1, \dots, p_K — доли объектов классов $1, \dots, K$ в R

1) Misclassification criteria: $H(R) = 1 - p_{max}$

2) Entropy criteria:

$$H(R) = - \sum_{k=1}^K p_k \ln p_k$$

3) Gini criteria:

$$H(R) = \sum_{k=1}^K p_k (1 - p_k)$$

Критерии построения разбиений

$H(R)$ — мера «неоднородности» множества R

Чтобы решать задачу регрессии, достаточно взять среднеквадратичную ошибку в качестве $H(R)$:

$$H(R) = \frac{1}{|R|} \sum_{x_i \in R} (y_i - \bar{y})^2$$

Критерии построения разбиений


$H(R)$ — мера «неоднородности» множества R

Чтобы решать задачу регрессии, достаточно взять среднеквадратичную ошибку в качестве $H(R)$:

$$H(R) = \frac{1}{|R|} \sum_{x_i \in R} (y_i - \bar{y})^2$$

$$\bar{y} = \frac{1}{|R|} \sum_{x_i \in R} y_i$$

Пример из ODS курса





Entropy criteria

$$H(X) = - \sum_{i=1}^N p_i \log_2 p_i$$

$$\frac{13}{20} * H_l + \frac{7}{20} * H_r \approx 0.83$$

$$S_0 = -\frac{9}{20} \log_2 \frac{9}{20} - \frac{11}{20} \log_2 \frac{11}{20} \approx 1$$



$$H_l = -\frac{5}{13} \log_2 \frac{5}{13} - \frac{8}{13} \log_2 \frac{8}{13} \approx 0.96$$

$$H_r = -\frac{1}{7} \log_2 \frac{1}{7} - \frac{6}{7} \log_2 \frac{6}{7} \approx 0.6$$

Gini criteria


$$p_k = \frac{1}{X} \sum_{i \in X} [y_i = k]$$

$$H(X) = \sum_{k=1}^K p_k (1 - p_k)$$

$$H(X) = 1 - \sum_k (p_k)^2$$

$$Q = \frac{13}{20} * H_r + \frac{7}{20} * H_l \approx 0.33$$

$$S_0 = 1 - \left(\frac{9}{20}\right)^2 - \left(\frac{11}{20}\right)^2 = 0.495$$





$$H_l = 1 - \left(\frac{5}{13}\right)^2 - \left(\frac{8}{13}\right)^2 \approx 0.38 \quad H_l = 1 - \left(\frac{1}{7}\right)^2 - \left(\frac{6}{7}\right)^2 \approx 0.24$$


Prunning

- Pre-prunning:
 - Ограничиваем рост дерева до того как оно построено
 - Если в какой-то момент информативность признаков в разбиении меньше порога – не разбиваем вершину
- Post-prunning:
 - Упрощаем дерево после того как дерево построено


Post-pruning



Бинаризация



$$\varphi(x) = [a_k < x \leq a_{k+1}]$$




Вариации алгоритма построения

- C4.5
- C5.0
- CART

II. Ансамбли деревьев


Random Forest

1. Генерируем M выборок на основе имеющейся (по схеме выбора с возвращением)




Random Forest

1. Генерируем M выборок на основе имеющейся (по схеме выбора с возвращением)
2. Строим на них деревья с рандомизированными разбиениями в узлах: выбираем k случайных признаков и ищем наиболее информативное разбиение по ним

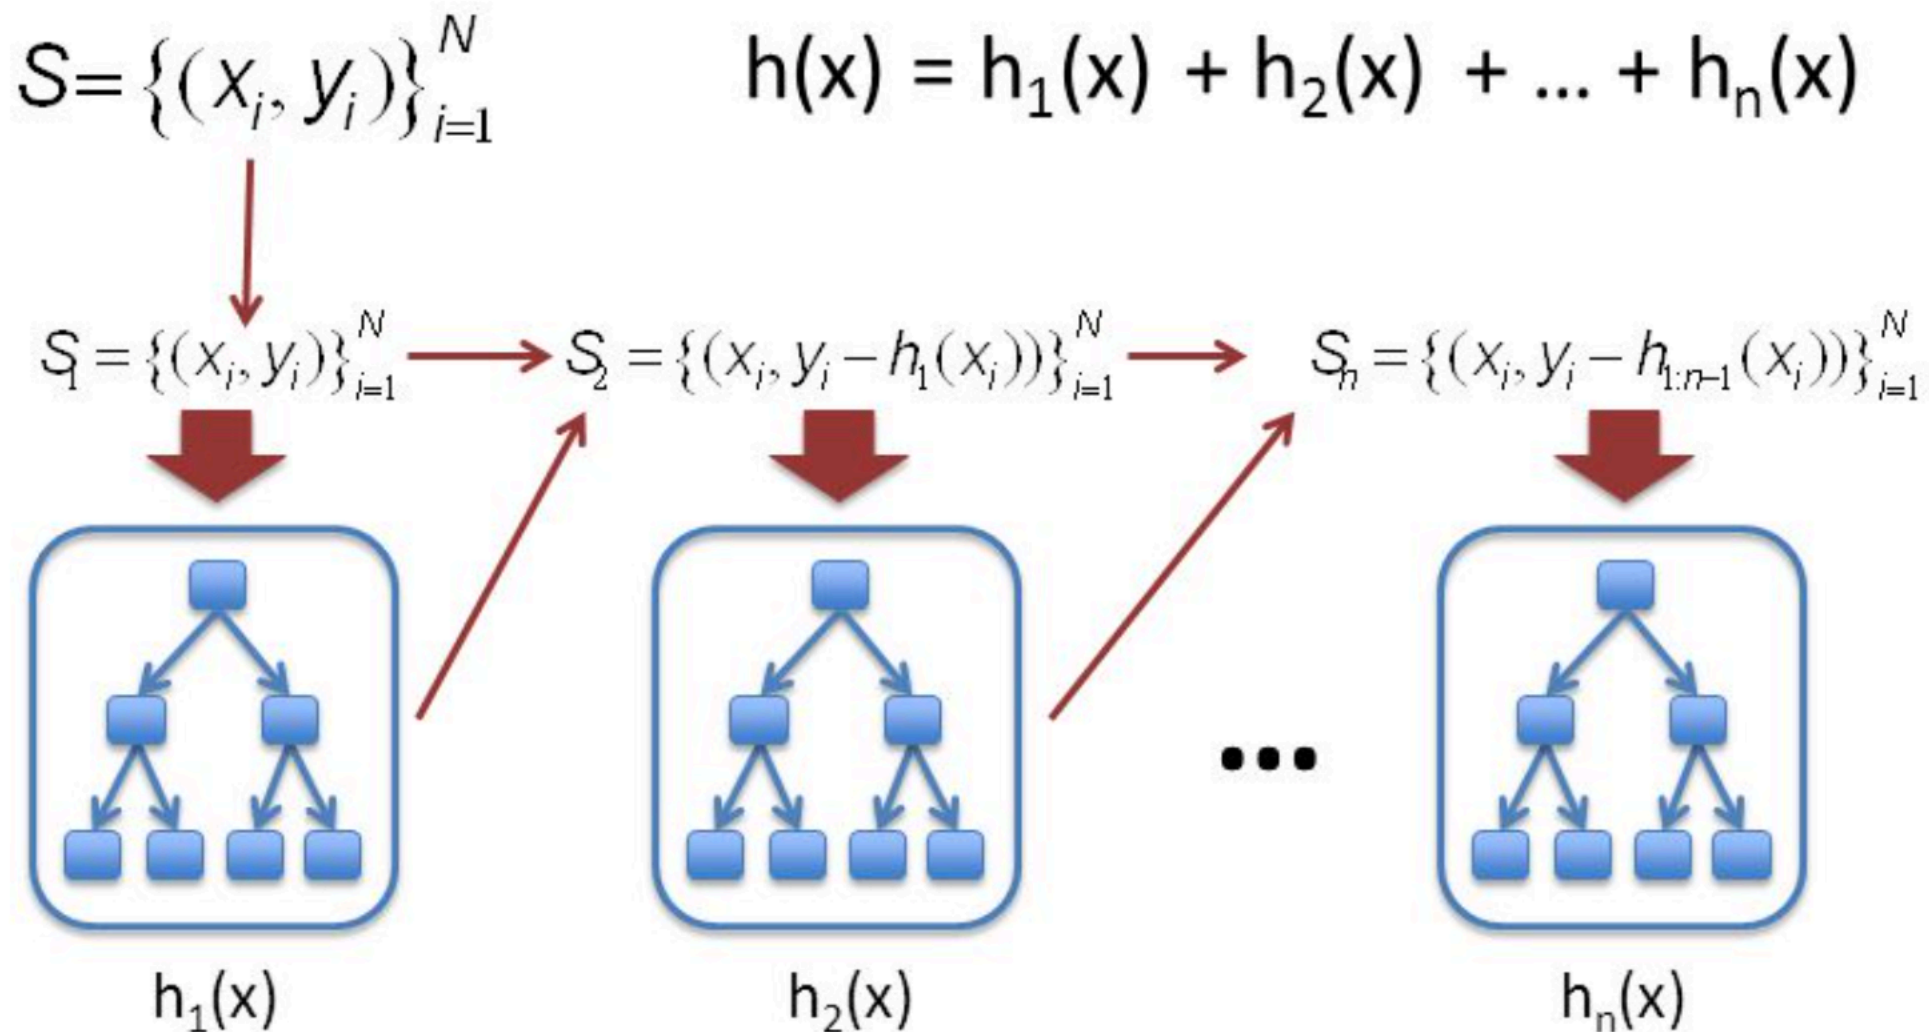


Random Forest

1. Генерируем M выборок на основе имеющейся (по схеме выбора с возвращением)
2. Строим на них деревья с рандомизированными разбиениями в узлах: выбираем k случайных признаков и ищем наиболее информативное разбиение по ним
3. При прогнозе усредняем ответ всех деревьев




Идея Gradient Boosted Decision Trees (GBDT)



III. kNN

kNN - классификатор



IV. SVM

SVM - классификатор

S – Support

V – Vector

M –

SVM - классификатор

S – Support

V – Vector


M – Магия

SVM - классификатор

S – Support

V – Vector

M – ~~Магия~~ Machine



Точно будет решение.

Так или иначе.


Причём само.

SVM - классификатор

S – Support

V – Vector (геометрия?)

M – ~~Магия~~ Machine



Точно будет решение.

Так или иначе.

Причём само.

SVM - классификатор

S – Support

V – Vector (геометрия?)

M – Магия Machine


$$w_1x_1 + w_2x_2 + \dots + w_nx_n + w_0 = 0$$

разделяющая гиперплоскость

Точно будет решение.

Так или иначе.

Причём само.

SVM - классификатор

S – Support

V – Vector (геометрия?)

M – Магия Machine

Точно будет решение.
Так или иначе.
Причём само.


$$w_1x_1 + w_2x_2 + \dots + w_nx_n + w_0 = 0$$

разделяющая гиперплоскость

$$a(x) = \text{sign} \left(\sum_{j=1}^n w_j x^j - w_0 \right) = \text{sign} (\langle w, x \rangle - w_0)$$

SVM - классификатор

S – Support (???)

V – Vector (геометрия?)

M – Магия Machine

Точно будет решение.
Так или иначе.
Причём само.


$$w_1x_1 + w_2x_2 + \dots + w_nx_n + w_0 = 0$$

разделяющая гиперплоскость

$$a(x) = \text{sign} \left(\sum_{j=1}^n w_j x^j - w_0 \right) = \text{sign} (\langle w, x \rangle - w_0)$$

SVM - классификатор

$$Q(w, w_0) = \sum_{i=1}^{\ell} [y_i(\langle w, x_i \rangle - w_0) < 0]$$

S – Support (???)

V – Vector (геометрия?)

M – Магия Machine

$$w_1x_1 + w_2x_2 + \dots + w_nx_n + w_0 = 0$$

разделяющая гиперплоскость

$$a(x) = \text{sign} \left(\sum_{j=1}^n w_j x^j - w_0 \right) = \text{sign}(\langle w, x \rangle - w_0)$$

Точно будет решение.

Так или иначе.

Причём само.

SVM - классификатор

$$Q(w, w_0) = \sum_{i=1}^{\ell} [y_i(\langle w, x_i \rangle - w_0) < 0]$$

S – Support (???)

V – Vector (геометрия?)

M – Магия Machine

$$w_1x_1 + w_2x_2 + \dots + w_nx_n + w_0 = 0$$

разделяющая гиперплоскость


$$a(x) = \text{sign} \left(\sum_{j=1}^n w_j x^j - w_0 \right) = \text{sign}(\langle w, x \rangle - w_0)$$

Точно будет решение.

Так или иначе.

Причём само.

SVM - классификатор



SVM - классификатор

$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{\langle w, x_+ \rangle - \langle w, x_- \rangle}{\|w\|} = \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|}$$

SVM - классификатор

$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{\langle w, x_+ \rangle - \langle w, x_- \rangle}{\|w\|} = \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|}$$

$$\langle w, x_i \rangle - w_0 \begin{cases} \leq -1, & \text{если } y_i = -1; \\ \geq 1, & \text{если } y_i = +1; \end{cases}$$

SVM - классификатор

$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{\langle w, x_+ \rangle - \langle w, x_- \rangle}{\|w\|} = \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|}$$

$$\begin{cases} \langle w, w \rangle \rightarrow \min; \\ y_i(\langle w, x_i \rangle - w_0) \geq 1, \quad i = 1, \dots, \ell. \end{cases}$$

$$\langle w, x_i \rangle - w_0 \begin{cases} \leq -1, & \text{если } y_i = -1; \\ \geq 1, & \text{если } y_i = +1; \end{cases}$$

SVM - классификатор

$$\begin{cases} \langle w, w \rangle \rightarrow \min; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1, \quad i = 1, \dots, \ell. \end{cases}$$

SVM - классификатор

$$\begin{cases} \langle w, w \rangle \rightarrow \min; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1, \quad i = 1, \dots, \ell. \end{cases}$$

Теорема Куна-Таккера

SVM - классификатор

$$\begin{cases} \langle w, w \rangle \rightarrow \min; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1, \quad i = 1, \dots, \ell. \end{cases} \quad + \quad \text{Теорема Куна-Таккера}$$

SVM - классификатор

$$\begin{cases} \langle w, w \rangle \rightarrow \min; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1, \quad i = 1, \dots, \ell. \end{cases} \quad + \quad \text{Теорема Куна-Таккера}$$

==

$$\begin{cases} \mathcal{L}(w, w_0; \lambda) = \frac{1}{2} \langle w, w \rangle - \sum_{i=1}^{\ell} \lambda_i (y_i (\langle w, x_i \rangle - w_0) - 1) \rightarrow \min_{w, w_0} \max_{\lambda}; \\ \lambda_i \geq 0, \quad i = 1, \dots, \ell; \\ \lambda_i = 0, \quad \text{либо} \quad \langle w, x_i \rangle - w_0 = y_i, \quad i = 1, \dots, \ell; \end{cases}$$

двойственная задача поиска седловой точки функции Лагранжа

SVM - классификатор

$$\left\{ \begin{array}{l} -\mathcal{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j (\langle x_i, x_j \rangle) \rightarrow \min_{\lambda}; \\ \lambda_i \geq 0, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{array} \right.$$

SVM - классификатор

$$\left\{ \begin{array}{l} -\mathcal{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j (\langle x_i, x_j \rangle) \rightarrow \min_{\lambda}; \\ \lambda_i \geq 0, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{array} \right.$$

$$w = \sum_{i=1}^{\ell} \lambda_i y_i x_i$$

SVM - классификатор

$$\begin{cases} -\mathcal{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j (\langle x_i, x_j \rangle) \rightarrow \min_{\lambda}; \\ \lambda_i \geq 0, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{cases}$$

$$w = \sum_{i=1}^{\ell} \lambda_i y_i x_i$$

$$a(x) = \text{sign} \left(\sum_{i=1}^{\ell} \lambda_i y_i \langle x_i, x \rangle - w_0 \right)$$

SVM - классификатор

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

SVM - классификатор

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

$$\begin{cases} -\mathcal{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle \rightarrow \min_{\lambda}; \\ 0 \leq \lambda_i \leq C, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{cases}$$

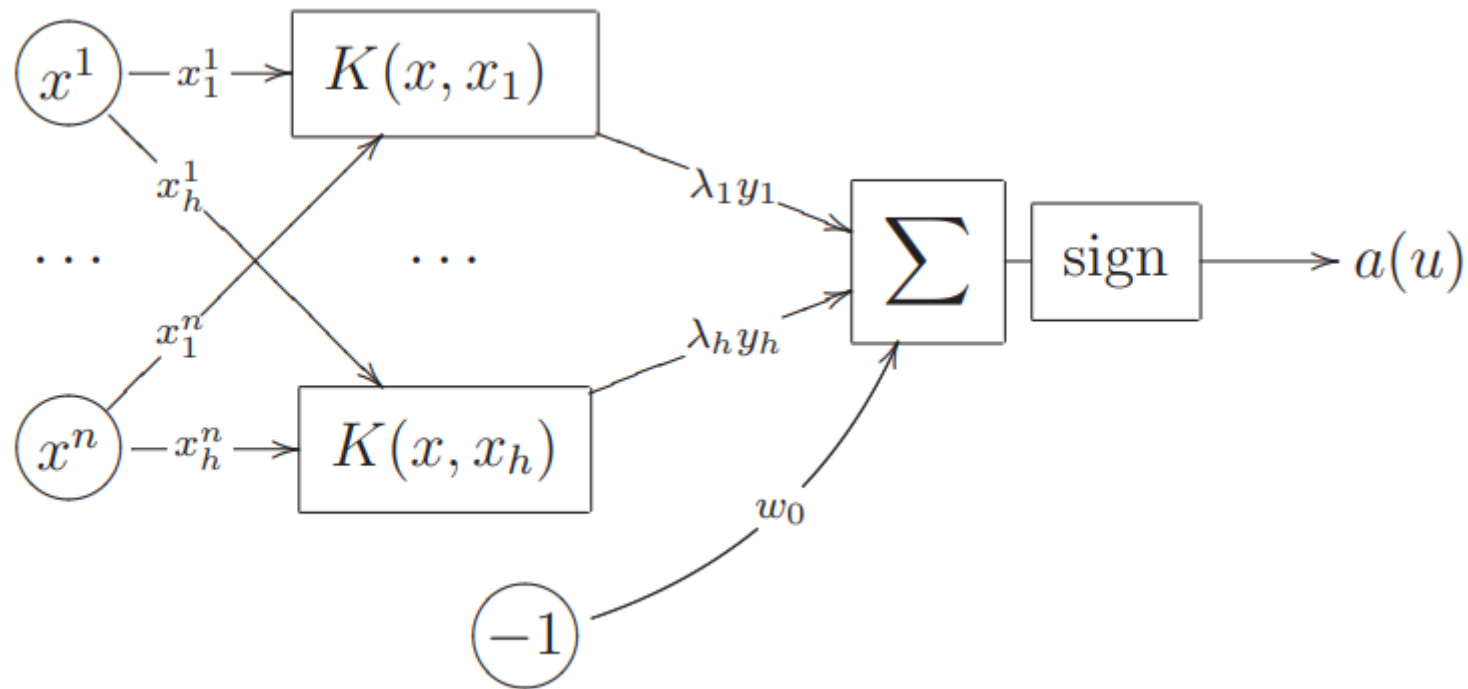
SVM - классификатор

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

$$\begin{cases} -\mathcal{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle \rightarrow \min_{\lambda}; \\ 0 \leq \lambda_i \leq C, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{cases}$$

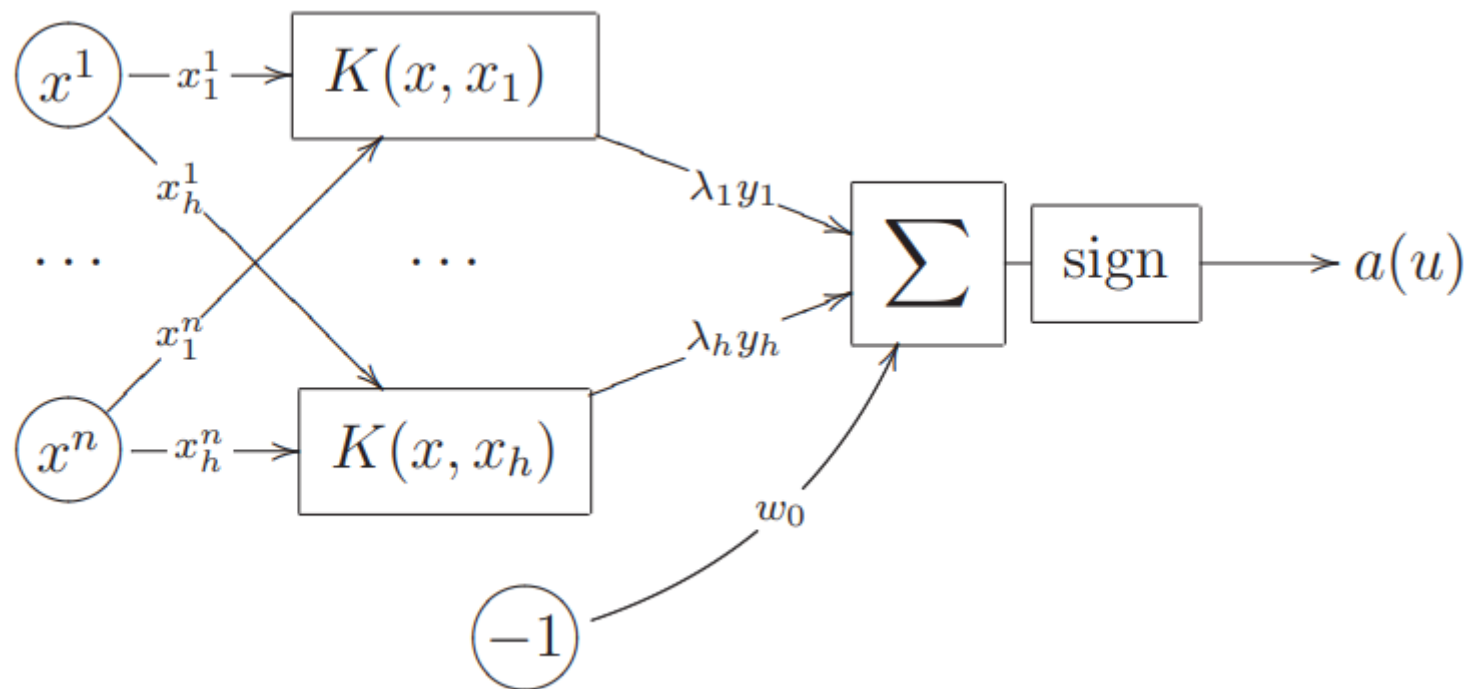
$$a(x) = \text{sign} \left(\sum_{i=1}^{\ell} \lambda_i y_i \langle x_i, x \rangle - w_0 \right)$$

SVM - классификатор

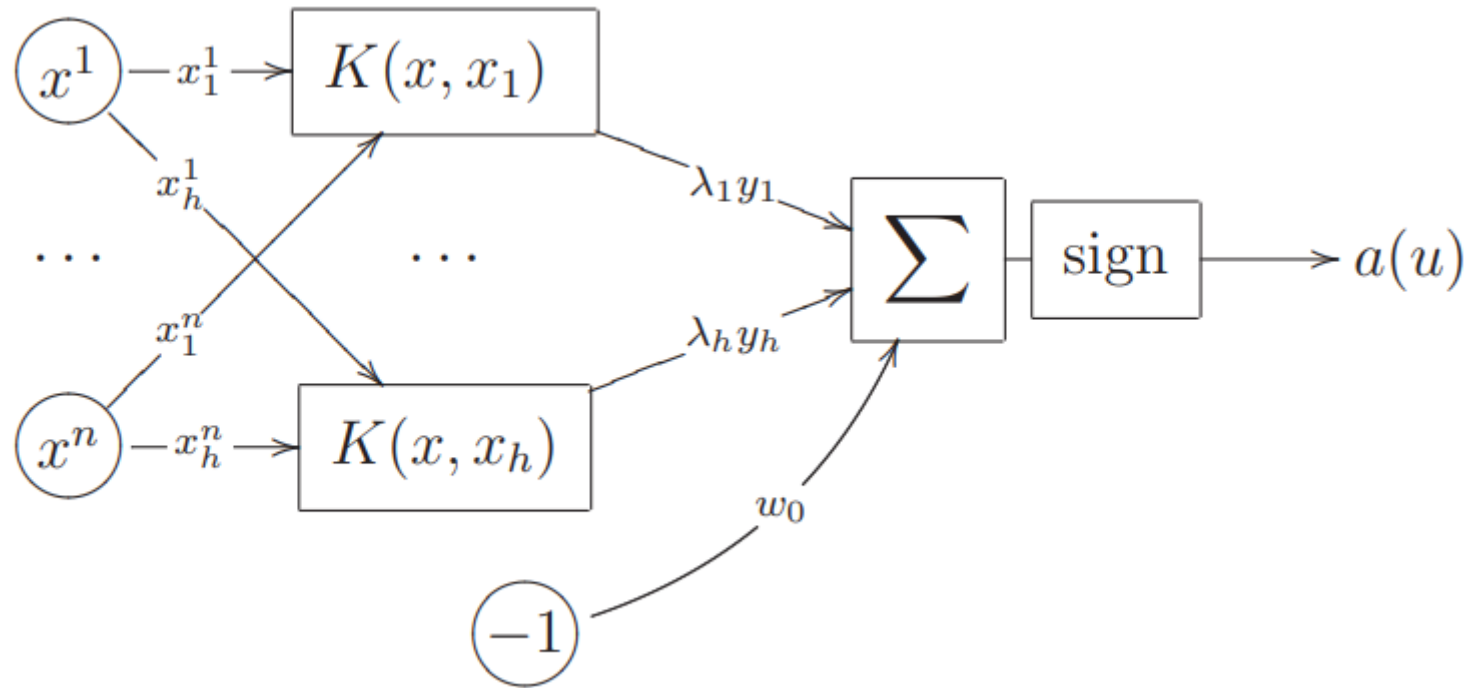


$$a(x) = \text{sign} \left(\sum_{i=1}^h \lambda_i y_i K(x_i, x) - w_0 \right)$$

SVM - классификатор



SVM - классификатор



$$a(x) = \text{sign} \left(\sum_{i=1}^h \lambda_i y_i K(x_i, x) - w_0 \right)$$